基于 LibEER 的 EEG 情绪识别复现实践报告

1．项目与复现动机

- LibEER 基准框架的设计初衷：该框架旨在解决 EEG 情绪识别领域中长期存在的评估协议不一致、预处理流程碎片化、结果难以横向比较的问题。LibEER 从数据预处理（重采样、带通滤波、基线校正）、特征提取（微分熵）、到评估协议（受试者依赖 SD 与受试者独立 SI）建立了完整标准化流程，为不同算法提供公平的比较基准。

我复现的工程背景：

- 原论文代码库（LibEER）在 Colab 环境下存在一定使用门槛，且论文报告的性能数据（如 DGCNN 在 SEED 数据集 SI 协议下约 85%）与我实际可获取的 Kaggle 公开数据集（Feeling Emotions）的原始格式存在差异。我需要在理解论文标准化思想的基础上，独立搭建一个可运行的简化流程。

我的复现目标：

- 在 Colab 上使用 Kaggle 公开数据集，搭建一个符合 LibEER 基础思想的 1D-CNN 分类流程，实现三分类情绪识别（消极/中性/积极），并通过实际运行结果反向审视论文所批判的“评估协议不一致”问题。

2．我的具体实践工作

环境与数据准备：

- 通过 Kaggle 公开数据集 URL 直接从官方网页链接下载数据集 [birdy654/eeg-brainwave-dataset-feeling-emotions](https://www.kaggle.com/datasets/birdy654/eeg-brainwave-dataset-feeling-emotions)，未使用 API 密钥或身份验证

数据预处理：

- 执行标签编码：将 NEGATIVE、NEUTRAL、POSITIVE 映射为 0、1、2。
- 执行 Z-score 标准化：对全部 2548 维特征向量进行均值为 0、标准差为 1 的缩放。
- 将数据转换为 PyTorch 张量，并增加通道维度（unsqueeze(1)），使其形状适配 1D 卷积输入格式 (batch, 1, features)。

模型构建：

- 自定义实现了一个三层 1D 卷积神经网络（EEG_CNN），结构包括：
  Conv1d(1→32, k=5) + BN + ReLU + MaxPool1d(2)
  Conv1d(32→64, k=5) + BN + ReLU + MaxPool1d(2)
  Conv1d(64→128, k=3) + BN + ReLU + MaxPool1d(2)
  自动计算展平后维度，接入两个全连接层（256 → 3），含 Dropout(0.5) 正则化。
- 训练配置：AdamW 优化器（lr=0.001）、交叉熵损失、batch size=32、epochs=40。

评估方式：

- 采用 train_test_split(test_size=0.2, random_state=42) 进行受试者依赖（SD）划分，即随机打乱所有样本后切分训练/测试集。
- 记录每个 epoch 的训练损失和测试准确率，保存最佳模型（按最高测试准确率）。

3．关键发现与批判性分析

- 99.5% 准确率的解析：
  运行结果最终测试准确率达到 99.5%，分类报告显示三类情绪的精确率、召回率均接近 1.0。然而这一结果并非模型真正学会了跨被试的情绪识别能力，而是由评估协议导致的数据泄露所致。
  - 问题根源：Subject-Dependent 协议下的被试数据泄露
  - 我所用的 train_test_split 是随机打乱全部样本后划分。由于同一个受试者

的多条脑电记录在数据集中是相互独立的行，打乱后该受试者的部分样本进入训练集，部分进入测试集。

- EEG 信号具有极强的个体特异性—每个人的脑电“指纹”相对稳定。模型在训练过程中学会的是“这段波形是张三的，张三此时是高兴”，而非“高兴情绪对应的通用脑电模式”。因此，模型在测试集上看到张三的另一条样本时，只需认出“这是张三”即可高概率猜对情绪标签，从而获得虚高的准确率。

- 论文观点在我实验中的直接印证：
  LibEER 论文明确指出，Subject-Dependent 协议因存在被试内数据混合，无法评估模型的跨被试泛化能力，其报告的高准确率不能作为算法真实水平的证据。我跑出的 99.5% 正是这一论述的鲜活例证。

4．改进方向与后续建议

评估协议的根本性升级：

- 必须放弃随机打乱划分，改用 Leave-One-Subject-Out (LOSO) 跨被试验证。
- 前提是需要数据集中包含真实的受试者 ID 字段。当前使用的 Kaggle 数据集缺失该信息，因此无法直接实施。未来若迁移至 SEED、DEAP 等含被试标签的数据集，可立即应用此协议。

预处理流程的补全：

- 当前仅做了 Z-score 标准化。标准 EEG 预处理还应包括：
  1–50 Hz 带通滤波：去除眼电、肌电等伪迹和工频噪声。
  微分熵（DE）特征提取：在 δ、θ、α、β、γ 五个频段分别计算 DE，比原始信号在情绪识别任务中更具判别力。
- 上述操作需要原始时序 EEG 数据，而非我当前使用的预提取特征向量（2548 维）。因此现阶段无法实施，需更换数据集。

模型结构的空间信息引入：

- 当前 1D-CNN 仅沿特征维度做时序卷积，完全忽略了 EEG 电极之间的空间拓扑关系。
- 未来可采用 LibEER 中验证有效的 DGCNN（动态图卷积网络），通过图卷积层学习不同脑区间的功能连接模式，同时捕获时间与空间特征。
- 实现： torch_geometric 或 torcheeg 库，但需配合电极位置坐标构建邻接矩阵。

训练策略的精细化：

- 引入早停机制（patience=20），防止过拟合。
- 使用 K 折交叉验证（在 LOSO 基础上进一步内层交叉）以更充分利用有限数据。